

Տվյալների Վերլուծություն **Pandas-ով**

Առաջին քայլերը ML մոդելավորումից առաջ. Data Pipeline & EDA

Քայլ 1 — Գրադարանների Ներմուծում

Python-ի հիմնական գործիքակազմը տվյալների վերլուծության համար

Գործիքների Ղերը Pipeline-ում

```
import pandas as pd
import numpy as np
```

Pandas & NumPy

pandas: Աշխատանք աղյուսակային տվյալների (DataFrame) հետ, տվյալների զտում, ձևափոխում և մաքրում:

numpy: Թվային հաշվարկներ, բազմաչափ զանգվածներ (arrays) և մաթեմատիկական գործողություններ:

```
import matplotlib.pyplot as plt
import seaborn as sns
```

Matplotlib & Seaborn

matplotlib: Հիմնական գրաֆիկների կառուցում (scatter plot, line plot, bar chart):

seaborn: Վիճակագրական վիզուալիզացիաներ, գեղեցիկ correlation heatmap-եր և բաշխվածության գրաֆիկներ:

Քայլ 2 — Dataset-ի Ստեղծում

```
data = { "area": [...], "price": [...] }  
df = pd.DataFrame(data)
```

Տվյալների Dictionary-ից DataFrame

Ստեղծում ենք ռեալիստիկ DataFrame 5 հիմնական սյունակով՝ հետագա վերլուծության համար:

Python Dictionary: Բանալիները դառնում են սյունակների անուններ, իսկ ցուցակները (lists)՝ տողերի արժեքներ:

Սյունակների Նկարագրությունը

- **area:** Տան մակերեսը (քմ)
- **bedrooms:** Ննջասենյակների քանակը
- **age:** Շենքի տարիքը (տարի)
- **location_score:** Տեղադրության միավորը (1-10)
- **price:** Տան գինը (Target)

Features vs Target Հարաբերությունը

-  **Features (Մուտքային հատկանիշներ):** area, bedrooms, age, location_score — Սրանք այն փոփոխականներն են, որոնք նկարագրում են օբյեկտը և օգտագործվում են կանխատեսման համար:
-  **Target (Նպատակային փոփոխական):** price — Արժեքը, որը ցանկանում ենք կանխատեսել (Supervised Learning-ի հիմքն է):
-  **Տրամաբանական կապը:** Մակերեսը և տեղադրության միավորը բարձրացնում են տան գինը, իսկ շենքի տարիքը սովորաբար նվազեցնում է այն:
-  **Pipeline-ի հաջորդականությունը:** Features → Machine Learning Model → Target Prediction

Քայլ 3 — Dataset-ի Առաջին Ձևումը

```
df.head() & df.shape
```

Ակնարկ և Չափսեր

df.head(): Ցույց է տալիս DataFrame-ի առաջին 5 տողերը՝ տվյալների տեսքն ու կառուցվածքը արագ հասկանալու համար:

df.shape: Վերադարձնում է տողերի և սյուների քանակը (մեր դեպքում՝ (10, 5) -> 10 տող, 5 սյուն):

```
df.info()
```

Կառուցվածք և Տիպեր

df.info(): Շատ կարևոր ֆունկցիա է, որը ցույց է տալիս .

- Սյունակների անունները
- Data Type-երը (int64, float64)
- Non-Null արժեքների քանակը և հիշողության ծավալը

Քայլ 4 – Թվային Վիճակագրություն

df.describe()

Վիճակագրական Ամփոփում

Հիմնական Մետրիկաները

- **count**: Ոչ դատարկ արժեքների քանակը
- **mean / std**: Միջին թվաբանականը և ստանդարտ շեղումը
- **min / max**: Նվազագույն և առավելագույն արժեքները
- **50% (Median)**: Կենտրոնական արժեքը (մեդիանան)
- **25% & 75%**: Քվարտիլները (միջակայքային տարածվածությունը)

Քայլ 5 — Missing Values Ստուգում



df.isnull().sum()

Ստուգում է յուրաքանչյուր սյունակում բացակայող (null/NaN) արժեքների ընդհանուր քանակը:



Մեր Dataset-ը


Բոլոր սյունակների համար արդյունքը 0 է, ինչը նշանակում է՝ բացակայող տվյալներ չունենք:



Եթե լինեին Null-եր

Պետք է որոշեինք՝ հեռացնել տողերը (dropna) թե լրացնել միջինով/մեդիանայով (fillna):

EDA Ամբողջական Փուլերը



Հաջորդ Փուլը — EDA Վիզուալիզացիա

Բաշխվածության Գրաֆիկներ

Histogram & KDE: Սյունակների (օր.՝ area, price) արժեքների տարածվածությունը և նորմալ բաշխումը տեսնելու համար:

Boxplot: Անոմալ արժեքները (outliers) և քվարտիլները հայտնաբերելու համար:

Փոխկապակցվածության Վերլուծություն

Scatter Plot: Երկու փոփոխականների միջև ուղիղ կամ հակադարձ կապը տեսնելու համար (օր.՝ area vs price):

Correlation Heatmap: Բոլոր սյունակների միջև կորելյացիոն գործակիցները (Pearson correlation) մեկ աղյուսակում:

“

«Տվյալները չեն խոսում, քանի դեռ դուք չեք տալիս
ճիշտ հարցեր:»

”

— Data Science Principle

Հարցեր ունե՞ք

Պատրաստ ենք անցնելու EDA-ի վիզուալ փուլին (Histogram, Scatter & Heatmap):

Data Science Masterclass | Python & Pandas Essentials