

Cross-Validation & Data Mismatch

Մեքենայական ուսուցման պրոյեկտների կարևորագույն բաղադրիչները.
ինչպես ճիշտ գնահատել մոդելը և խուսափել իրական տվյալների
թակարդներից:

Validation Set–ի չափի խնդիրը

Շատ փոքր Validation Set

Օրինակ՝ Validation = 20 օրինակ

- Model A → 90%, Model B → 95%
- Այս 20 օրինակները կարող են պատահականորեն չներկայացնել իրական տվյալները:
- Արդյունքում կարող ենք ընտրել սխալ մոդել:

Շատ մեծ Validation Set

Օրինակ՝ Training = 50%, Validation = 50%

- Candidate մոդելները train ենք անում չափազանց փոքր training set-ի վրա:
- Համեմատությունն այնքան էլ արդար չէ, քանի որ վերջնական մոդելը սովորելու է ամբողջ տվյալներով:

Cross-Validation 🔥

- 📦 **Գաղափարը:** Training data-ն բաժանում ենք մի քանի փոքր մասերի (folds), օրինակ՝ 5-fold:
- 🔄 **Պրոցես:** Մոդելը train/test ենք անում 5 անգամ, որտեղ ամեն անգամ մեկ fold-ը ծառայում է որպես validation, իսկ մնացածը՝ training:
- 📈 **Արդյունք:** Ստանում ենք 5 validation scores, որոնց միջինացված արժեքը տալիս է շատ ավելի վստահելի գնահատական:
- 🕒 **Թերություն:** Պահանջում է ավելի շատ հաշվողական ռեսուրսներ և ժամանակ (train անել 5 կամ 10 անգամ):

Data Mismatch 🚨 (Իրական խնդիր)

Training Data (Web Images)

Հեշտ է գտնել համացանցից (օրինակ՝ 1,000,000 նկար):

- Պրոֆեսիոնալ տեսախցիկներ
- Ստուդիական լուսավորություն
- Կատարյալ ֆոն և բարձր որակ

Production Data (Mobile Photos)

Այն, ինչ օգտագործվելու է իրական բջջային հավելվածում:

- Սովորական բջջային հեռախոսի նկարներ
- Տարբեր և անկանոն լուսավորություն
- Աղմուկ և ոչ պերֆեկտ ֆոն

Ամենակարևոր Կանոնը Validation-ի Համար



Միսալ մոտեցում

Validation և Test սթեները վերցնել համացանցի (web images) տվյալներից: Այդ դեպքում մենք չենք իմանա, թե մոդելն ինչպես կաշխատի իրականում:



Ճիշտ մոտեցում

Validation-ը և Test-ը **պետք է** բաղկացած լինեն production-ին նմանվող տվյալներից (Mobile pictures), քանի որ մեզ հետաքրքրում է կատարումը հենց հավելվածում:

Validation Accuracy = 70%. Ինչո՞ւ:

Տարբերակ A — Overfitting

Մոդելը պարզապես վատ է սովորել training data-ն (web pictures): Այն չի կարողանում նույնիսկ վայելել ուսումնական տվյալների վրա լավ արդյունքը:

Տարբերակ B — Data Mismatch

Մոդելը հիանալի է սովորել web pictures-ի վրա, բայց խնդիրն այն է, որ Web տվյալները բոլորովին նման չեն Mobile տվյալներին (distribution-ների տարբերություն):

Լուծում. Train-Dev Set

-  **Բաշխման սխեմա:** Web Data-ն բաժանում ենք երկու մասի՝ Training և Train-dev: Mobile Data-ն բաժանում ենք Dev (Validation) և Test-ի:
-  **Ուսուցում:** Մոդելը train ենք անում միայն *Training* տվյալների վրա, ոչ թե Train-dev-ի:
-  **Ստուգման հաջորդականություն:** Համեմատում ենք Training, Train-dev, և Dev պերֆորմանսները՝ խնդրի իրական աղբյուրը գտնելու համար:

Միավորների Աղյուսակ 🧠

Training	Train-dev	Dev (Validation)	Ինչ է նշանակում
Լավ	Վատ	Վատ	Overfitting (մոդելը չի ընդհանրացնում)
Լավ	Լավ	Վատ	Data Mismatch (տվյալների անհամապատասխանություն)
Լավ	Լավ	Լավ	Լավ մոդել (հիմնալի աշխատանք)
Վատ	Վատ	Վատ	Underfitting (թույլ մոդել)

Ինչպե՞ս հաղթահարել Data Mismatch-ը

- ✂ **Preprocessing / Արհեստական մոտեցում:** Փորձել web images-ը դարձնել ավելի նման production images-ին:
- 🖼 **Աղմուկ և Ձևափոխում:** Կիրառել Crop, Resize, Blur, Lighting adjustment և Noise ֆիլտրեր web նկարների վրա:
- 🗄 **Հավաքել Real Data:** Հնարավորության դեպքում ավելացնել իրական mobile նկարների քանակը ուսումնական հավաքածուում (Artificial Data Synthesis):

Ամփոփում և Հիմնական Հասկացություններ

Cross-Validation: Validation-ը մի քանի անգամ փոխում ենք (folds), որպեսզի ստանանք ավելի վստահելի և կայուն գնահատական:

Data Mismatch: Training և Production տվյալները ունեն տարբեր distribution (տարածում):

Train-Dev Set: Օգնում է հստակ տարբերել Overfitting-ը Data Mismatch-ից:

Ոսկե կանոն: Validation և Test սթները պետք է հնարավորինս ճշգրիտ կերպով արտացոլեն այն միջավայրը, որտեղ աշխատելու է մոդելը: