

Exploratory Data Analysis

Տվյալների վերլուծություն, բաշխվածությունների և փոխկապակցվածությունների (Correlation) բացահայտում Python-ում նախքան մոդելավորումը:

EDA-ի Հիմնական Փուլերը

EDA-ի նպատակը միանգամից Model կառուցելը չէ, այլ տվյալների կառուցվածքն ու օրինաչափությունները հասկանալը:



☰ Քայլ 6 — Distribution: `plt.hist()`

Ի՞նչ է անում `plt.hist()`-ը

- ✓ Թվային տվյալները բաժանում է միջակայքերի (**bins**):
- ✓ Ցույց է տալիս, թե որ միջակայքում են գտնվում հիմնական արժեքները (օր.՝ **Price**):
- ✓ Թույլ է տալիս գնահատել տվյալների սիմետրիկությունը կամ լիթվածությունը (**Skewness**):

```
# Price-ի բաշխվածության կառուցումը import matplotlib.pyplot  
as plt plt.figure(figsize=(8, 5)) plt.hist(df["price"],  
bins=8, edgecolor="black") plt.xlabel("Price")  
plt.ylabel("Number of Houses") plt.title("Distribution of  
House Prices") plt.show()
```

Քալ 7 — Boxplot & Outlier-ներ

Outlier-ների Հայտնաբերում

Boxplot-ը հնարավորություն է տալիս տեսնել մեդիան, քվանտիլները և հեռու ընկած արժեքները (outliers):

Q1 (25%) - Median - Q3 (75%)

IQR

Եթե առանձին կետեր կան box-ի սահմաններից (whiskers) դուրս, դրանք պոտենցիալ outlier-ներ են:

```
# Seaborn boxplot-ի կիրառումը import seaborn as sns
plt.figure(figsize=(8, 4)) sns.boxplot(x=df["price"])
plt.title("Price Boxplot") plt.show()
```

❖ Քայլ 8 — Բոլոր Feature-ների Overview

`df.hist()` Արագ Ստուգում

Pandas-ը ավտոմատ կերպով կառուցում է հիստոգրամ յուրաքանչյուր թվային սյունակի համար (Area, Bedrooms, Age, Location Score, Price):

- ⚡ 1 տող կոդով ամբողջական overview:
- 👁 Հնարավորություն է տալիս արագ նկատել անանոմալիաները:

```
# Բոլոր numeric columns-ի histogram-ները df.hist( figsize=(12, 8), bins=10 ) plt.tight_layout() plt.show()
```

Քայլ 9 — Feature vs Target: Area vs Price

Positive Linear Relationship

Scatter plot-ը ցույց է տալիս երկու փոփոխականների միջև կախվածությունը:

- ↗ Եթե **Area**-ն մեծանում է $\rightarrow$ **Price**-ը նույնպես մեծանում է:
- ✓ Սա ապացուցում է, որ **Linear Regression** մոդելն այստեղ իմաստ ունի:

```
# Scatter plot: Area vs Price plt.figure(figsize=(8, 5))
plt.scatter( df["area"], df["price"], color="royalblue",
s=80, alpha=0.7 ) plt.xlabel("Area") plt.ylabel("Price")
plt.grid(alpha=0.3) plt.show()
```

Քայլ 10 — Մյուս Feature-ների Ստուգումը




Bedrooms vs Price

Սովորաբար ցույց է տալիս դրական կապ, բայց արժեքները դիսկրետ են (1, 2, 3, 4...):



Age vs Price

Տան տարիքի մեծացման հետ գինը հնարավոր է նվազի (**Negative Relationship**):



Location Score vs Price

Տեղադրության բարձր միավորը ուղղակիորեն բարձրացնում է տան արժեքը:

📊 Քայլ 11 — Correlation Matrix: `df.corr()`

Կորելյացիայի Միջակայքը

+1.0 Ուժեղ Positive Կապ (օր. Area ↔ Price = 0.95)

0.0 Գծային կապ չկա

-1.0 Ուժեղ Negative Կապ (օր. Age ↔ Price = -0.80)

⚠️ **Correlation ≠ Causation**

```
# Correlation Matrix հաշվարկը correlation = df.corr()
print(correlation) ''' Output Matrix: area bedrooms age
price area 1.00 0.65 -0.30 0.95 bedrooms 0.65 1.00 -0.10
0.72 age -0.30 -0.10 1.00 -0.80 price 0.95 0.72 -0.80
1.00 '''
```

🔥 Բալլ 12 — Correlation Heatmap

Heatmap-ի Պարամետրերը

annot=True — Cell-երի մեջ գրում է correlation-ի թվային արժեքները:

🧠 **cmap="coolwarm"** — Գույների պալիտրա (Կարմիր = Positive, Կապույտ = Negative):

⚙️ **fmt=".2f"** — Կլորացնում է 2 տասնորդականի:

```
# Heatmap-ի պատրաստումը Seaborn-ով plt.figure(figsize=(9, 6)) sns.heatmap( df.corr(), annot=True, cmap="coolwarm", fmt=".2f", linewidths=0.5 ) plt.title("Correlation Heatmap") plt.show()
```

Հաջորդ ֆալը՝ Machine Learning



1. Separate X and y

Առանձնացնում ենք Feature-ները (X)
target փոփոխականից (`y = price`):



2. Train/Test Split

Տվյալները բաժանում ենք ուսուցանող
(Train) և թեստավորող (Test)
հատվածների:



3. Linear Regression

Վարժեցնում ենք մոդելը
`LinearRegression().fit(X_train,
y_train)`՝ հրամանով: