

MACHINE LEARNING OVERVIEW

Մեքենայական Ուսուցման 8 Հիմնարար Ալգորիթմները

Տեսական հիմունքներ, աշխատանքի սկզբունք, real-world կիրառություններ,
առավելություններ և թերություններ

 Supervised Learning

 Unsupervised Learning

 Regression & Classification

Ալգորիթմների Քարտեզագրում

Supervised Learning

Regression (Ռեգրեսիա)

Անընդհատ թվային արժեքների կանխատեսում

- Linear Regression

Classification (Դասակարգում)

Տվյալների բաժանում նախապես որոշված դասերի

- Logistic Regression
- k-NN
- Random Forest

Unsupervised Learning

Clustering (Կլաստերավորում)

Նմանատիպ տվյալների ավտոմատ խմբավորում

- k-Means
- DBSCAN

Anomaly Detection (Անոմալիաներ)

Շեղումների և կասկածելի կետերի հայտնաբերում

- Isolation Forest
- Gaussian Mixture Models (GMM)

1. Linear Regression (Գծային)

SUPERVISED • REGRESSION

Ի՞նչ է սա և Ինչպե՞ս է աշխատում

Օգտագործվում է **անընդհատ թվային արժեքներ** կանխատեսելու համար: Ալգորիթմը տվյալների միջով անցկացնում է լավագույն «ուղիղ գիծը»՝ նվազագույնի հասցնելով քառակուսային սխալը (Mean Squared Error - MSE):

$$\hat{y} = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

Իրական Օրինակ (Real-World Use Case)

Տան գների կանխատեսում. Մուտք՝ մակերես (x_1), սենյակներ (x_2), հեռավորություն կենտրոնից (x_3): Ելք՝ տան գինը (y):

Առավելություններ

- Պարզ է, արագ և հեշտ իրականացնելի:
- Կշիռները (w) շատ հեշտ է մեկնաբանել (Interpretability):

Թերություններ

- Ենթադրում է գծային կապ, ինչն իրականում հազվադեպ է:
- Խիստ զգայուն է աղմուկի (Outliers) նկատմամբ:

2. Logistic Regression (Լոգիստիկ)

SUPERVISED • BINARY CLASSIFICATION

🎯 Ի՞նչ է սա և Ինչպե՞ս է աշխատում

Չնայած անվանմանը՝ **Classification** ալգորիթմ է երկուական (0 կամ 1) ելքերի համար: Գծային հավասարման ելքը փոխանցվում է **Sigmoid** ֆունկցիային, որը ստանում է 0-ից 1 հավանականություն:

Եթե Հավանականությունը $> 0.5 \rightarrow$ Դաս 1 | Եթե
Հավանականությունը $\leq 0.5 \rightarrow$ Դաս 0

📁 Իրական Օրինակներ

- Spam Detection:** Նամակում բառերի հիման վրա որոշել՝ սպամ է (1), թե ոչ (0):
- Բժշկական ախտորոշում:** Անալիզների հիման վրա հիվանդության առկայությունը:

👍 Առավելություններ

- Տալիս է հստակ հավանականային գնահատական (օր.՝ 85% սպամ):
- Շատ արդյունավետ է գծայնորեն բաժանելի տվյալների դեպքում:

👎 Թերություններ

- Լավ չի աշխատում ոչ գծային բարդ կապերի դեպքում:
- Պահանջում է հատկանիշների (Features) անկախություն:

3. k-Nearest Neighbors (k-NN)

SUPERVISED • INSTANCE-BASED / LAZY LEARNING

👥 Ի՞նչ է սա և Ինչպե՞ս է աշխատում

Lazy Learning ալգորիթմ է. չունի մարզման փուլ, հաշվարկը կատարվում է կանխատեսման պահին: Նոր կետի համար հաշվում է հեռավորությունը (Euclidean distance) բոլոր կետերից և գտնում ամենամոտ k հարևաններին:

- **Classification:** Տալիս է հարևանների մեջ գերակշռող դասը (քվեարկություն):
- **Regression:** Վերցնում է հարևանների արժեքների միջինը:

📊 Իրական Օրինակ

Ֆիլմերի առաջարկման համակարգեր. Եթե Օգտատեր A-ն դիտած ֆիլմերով նման է k այլ օգտատերերի, նրան առաջարկվում են այդ հարևանների դիտած ֆիլմերը:

👍 Առավելություններ

- Պարզ է, ինտուիտիվ և հեշտ հասկանալի:
- Չի անում կանխավ ենթադրություններ տվյալների բաշխման մասին:

👎 Թերություններ

- Դանդաղում է մեծ տվյալների դեպքում (ամեն անգամ հաշվում է բոլոր հեռավորությունները):
- Շատ զգայուն է չմշակված/չմասշտաբավորված տվյալների նկատմամբ:

4. Random Forest (Անտառ)

SUPERVISED • ENSEMBLE LEARNING

🌲 Ի՞նչ է սա և Ինչպե՞ս է աշխատում

Անսամբլային մեթոդ է՝ հիմնված բազմաթիվ Որոշումների Ծառերի (Decision Trees) վրա: Օգտագործում է **Bagging (Bootstrap Aggregating)** տեխնիկան.

1. Տվյալներից ընտրվում են պատահական ենթաբազմություններ:
2. Յուրաքանչյուրի վրա կառուցվում է անկախ Decision Tree:
3. Վերջնական որոշումն ընդունվում է մեծամասնության ձայներով:

🏛️ Իրական Օրինակ

Վարկային ռիսկի գնահատում. Բանկը վերլուծում է հաճախորդի եկամուտը, տարիքը, վարկային պատմությունը և որոշում՝ տալ վարկ, թե մերժել:

👍 Առավելություններ

- Բարձր ճշտություն, արդյունավետորեն կանխում է Overfitting-ը:
- Աշխատում է և՛ classification-ի, և՛ regression-ի հետ:

👎 Թերություններ

- Դժվար է մեկնաբանել (Black Box՝ 100+ ծառերի ներսը տեսնելն անհնար է):
- Պահանջում է շատ հիշողություն և հաշվողական resources-ներ:

5. k-Means Clustering

UNSUPERVISED • CLUSTERING

Ի՞նչ է սա և Ինչպե՞ս է աշխատում

Չվերահսկվող ալգորիթմ է տվյալների խմբավորման (Clustering) համար.

1. Ֆիքսվում է կլաստերների քանակը՝ K :
2. Պատահական ընտրվում են K կենտրոններ (Centroids):
3. Ամեն կետ վերագրվում է իրեն ամենամոտ կենտրոնին:
4. Կենտրոնները վերահաշվարկվում են որպես կետերի միջին տեղադիրք:
5. Կրկնվում է մինչև կենտրոնները դադարեն փոխվել:

Իրական Օրինակ

Հաճախորդների սեգմենտավորում. Մարկետոլոգները խմբավորում են գնորդներին ըստ ծախսերի և գնումների հաճախականության:

Առավելություններ

- Շատ արագ է և արդյունավետ մեծ տվյալների վրա:
- Պարզ է իրականացնել և հասկանալ:

Թերություններ

- Պետք է նախապես իմանալ կամ կռահել K -ի արժեքը:
- Վատ է աշխատում ոչ ոլորտաձև (non-spherical) կլաստերների հետ:

6. DBSCAN

UNSUPERVISED • DENSITY-BASED CLUSTERING

📍 Ի՞նչ է սա և Ինչպե՞ս է աշխատում

Density-Based Spatial Clustering: Խմբավորում է իրար մոտ տեղակայված (բարձր խտության) կետերը, իսկ ցածր խտության տարածքներում գտնվող կետերը պիտակավորում է որպես **Noise** (Աղմուկ):

⚙️ 2 հիմնական պարամետր՝ **eps** (շառավիղ) և **minPts** (նվազագույն կետերի քանակ):

📍 Իրական Օրինակ

Տաքսիների կանգառների քարտեզագրում. GPS տվյալների հիման վրա գտնել մարդկանց ամենաբարձր կուտակումները քաղաքում՝ անկախ դրանց ձևից:

👍 Առավելություններ

- Պետք չէ նախապես ասել կլաստերների քանակը (K):
- Գտնում է բարդ ցանկացած ձևի կլաստերներ և առանձնացնում աղմուկը:

👎 Թերություններ

- Վատ է աշխատում, եթե կլաստերներն ունեն տարբեր խտություններ:
- Զգայուն է **eps** և **minPts** պարամետրերի ընտրության նկատմամբ:

7. Isolation Forest

UNSUPERVISED • ANOMALY DETECTION

🛡️ Ի՞նչ է սա և Ինչպե՞ս է աշխատում

Հատուկ մշակված է **Anomaly Detection**-ի համար: Նորմալ տվյալները սովորելու փոխարեն, այն փորձում է **մեկուսացնել (isolate)** ամեն մի կետ պատահական բաժանումներով:

Քանի որ անոմալիաները քիչ են, դրանց մեկուսացնելու համար անհրաժեշտ են շատ ավելի քիչ բաժանումներ (կարճ ճանապարհ ծառի մեջ):

🏠 Իրական Օրինակ

Ֆինանսական խարդախությունների հայտնաբերում (Fraud Detection). Բանկային գործարքներում ակնթարթորեն գտնել կասկածելի փոխանցումները:

👍 Առավելություններ

- Շատ արագ է և քիչ հիշողություն է պահանջում (Linear time complexity):
- Արդյունավետ է բազմաչափ (high-dimensional) տվյալների հետ:

👎 Թերություններ

- Դժվար է վիզուալիզացնել և բացատրել, թե ԿՈՆԿՐԵՏ ԻՆՉՈՒ է կետը համարվել անոմալիա:

8. Gaussian Mixture Models (GMM)

UNSUPERVISED • PROBABILISTIC MODEL

🔍 Ի՞նչ է սա և Ինչպե՞ս է աշխատում

Հավանականային (Probabilistic) ալգորիթմ է Clustering-ի և Anomaly Detection-ի համար: Ենթադրում է, որ տվյալները գեներացվել են մի քանի **Գաուսյան (Նորմալ) բաշխումների** խառնուրդից:

Ի տարբերություն k-Means-ի (Hard Clustering), GMM-ը տալիս է **Soft Clustering** (օր.՝ կետը 70% պատկանում է A կլաստերին, 30%՝ B-ին):

🔗 Իրական Օրինակ

Ձայնի և ազդանշանների ճանաչում. Աուդիո ազդանշանների մոդելավորում և իրար ծածկող բարդ կլաստերների բաժանում:

👍 Առավելություններ

- Շատ ճկուն է. աշխատում է էլիպսաձև և իրար ծածկող կլաստերների հետ:
- Տալիս է հավանականային պատկանելություն (Soft Assignment):

⚠️ Թերություններ

- Զգայուն է սկզբնական պարամետրերի ընտրության նկատմամբ (EM algorithm):
- Կարող է ընկնել տեղային նվազագույնի (Local Minima) մեջ:

Ալգորիթմների Համեմատական Աղյուսակ

Ալգորիթմ	Տեսակ (Type)	Խնդիր (Task)	Հիմնական Առանձնահատկություն
Linear Regression	Supervised	Regression	Անընդհատ թվային արժեքներ, ուղիղ գիծ
Logistic Regression	Supervised	Classification	Sigmoid ֆունկցիա, հավանականային ելք
k-NN	Supervised	Class / Reg	Lazy Learning, հեռավորության հաշվարկ (k հարևան)
Random Forest	Supervised	Class / Reg	Ensemble, Bagging բազմաթիվ ծառերով
k-Means	Unsupervised	Clustering	Centroids-ի վրա հիմնված K խմբեր
DBSCAN	Unsupervised	Clustering	Խտության վրա հիմնված, աղմուկի առանձնացում
Isolation Forest	Unsupervised	Anomaly Detection	Անոմալիաների արագ մեկուսացում ծառերով
GMM	Unsupervised	Clustering / Anomaly	Soft Clustering, Գաուսյան բաշխումներ



Շնորհակալություն

Հարցեր և Քննարկում (Q&A)

Machine Learning & Data Science Core Algorithms