

Մեքենայական Ուսուցման Մարտահրավերները

Bad Data — Ինչու՞ նույնիսկ ճիշտ ալգորիթմը կարող է վատ աշխատել



Մարտահրավեր #1: Insufficient Quantity of Training Data

Տվյալների անբավարար քանակի խնդիրը

Մարդկային ուղեղը vs Machine Learning

Մարդկային ուղեղ

Երեխային բավական է ցույց տալ խնձորի մի քանի օրինակ (կարմիր, կանաչ, մեծ, փոքր), որպեսզի նա հեշտությամբ **generalize** **անի** և ճանաչի ցանկացած այլ խնձոր:

Machine Learning-ը

ML մոդելները սովորաբար շատ ավելի շատ օրինակների կարիք ունեն: Պարզ խնդիրների դեպքում (օրինակ՝ Spam Detection) հարկավոր են հարյուր հազարավոր, իսկ բարդ խնդիրների դեպքում՝ միլիոնավոր օրինակներ:

Transfer Learning & Data Power

 **Transfer Learning:** Եթե արդեն գոյություն ունի մեծ dataset-ի վրա trained model, կարող ենք օգտագործել դրա սովորած գիտելիքը՝ խնայելով ժամանակ և սեփական data-ի ծավալը:

 **The Unreasonable Effectiveness of Data:** Շատ բարդ խնդիրների դեպքում հսկայական քանակությամբ տվյալները կարող են ավելի կարևոր լինել, քան բարդ ալգորիթմի ընտրությունը:

600 × 400

Մարտահրավեր #2: Nonrepresentative Data

Ոչ ներկայացուցչական տվյալների վտանգը

GDP-ի և Կյանքի Ուրախության Օրինակը



Սահմանափակ Տվյալներ

Եթե training data-ում ունենանք միայն միջին հարուստ երկրներ (\$23,500 – \$62,500), մոդելը սխալ գծային օրինաչափություն (linear pattern) կսովորի:



Իրական Աշխարհի Խնդիրը

Նոր, շատ աղքատ կամ շատ հարուստ երկրներ ավելացնելիս տեսնում ենք, որ կապը միանշանակ չէ: Վատ representative data-ն բերում է վատ generalization-ի:

Sampling Noise vs Sampling Bias



Sampling Noise

Փոքր dataset-ի պատճառով ստացված պատահական շեղում (օրինակ՝ պատահաբար հարցված 10 ուսանողները բոլորը մարզիկներ էին):



Sampling Bias

Տվյալների հավաքագրման սխալ կամ կողմնակալ մեթոդ (օրինակ՝ հարցում անել միայն Apple Store-ի այցելուներին):



Արդյունքի Շղթան

Nonrepresentative data → Sampling Bias → Վատ generalization → Սխալ կանխատեսումներ ու ձախողում:

Քննարկման Հարց

Ըստ ձեզ, եթե ունենանք անսահմանափակ քանակությամբ տվյալներ, բայց դրանք լինեն խիստ կողմնակալ (biased), արդյո՞ք մոդելը լավ կաշխատի իրական կյանքում: