

MACHINE LEARNING • CHAPTER 2

California Housing Dataset & Practical Exercises

Python ֆունկցիաների կիրառություն, շերտավորված նմուշառում և ML
Detective վերլուծություն



EXERCISE 1

Dataset–ի արագ ուսումնասիրություն (Python Functions)

Կիրառվող Ֆունկցիաներ

```
housing.head()  
housing.info()  
housing.describe()  
housing.isnull().sum()
```

Այս ֆունկցիաներն օգնում են միանգամից տեսնել **20,640** տող (instance), **10** սյուն (feature), ինչպես նաև հայտնաբերել բաց թողնված **207** հատ արժեք total_bedrooms սյունում:

Հիմնական Բացահայտումներ

head(): Ցույց է տալիս առաջին 5 մուշները և տվյալների տեսքը:

info(): Հաստատում է data types-ը և non-null counts-ը:

describe(): Բացահայտում է median_house_value-ի արեեստական շենը (max 500k):

Categorical: ocean_proximity-ն միակ տեքստային սյունն է:

EXERCISE 2

median_income-ի կատեգորիզացիա (pd.cut)

Կիրառվող Կոդը

```
housing["income_cat"] = pd.cut(  
    housing["median_income"],  
    bins=[0., 1.5, 3.0, 4.5, 6., np.inf],  
    labels=[1, 2, 3, 4, 5]  
)  
housing["income_cat"].value_counts().plot.bar()
```

Նպատակը: Շարունակական արժեքը բաժանել դիսկրետ 5 խմբերի՝
շերտավորված մոլշառման համար:

Կատեգորիաների Բաշխում (%)

Category 1 (0–1.5): ~3.0%

Category 2 (1.5–3): ~31.9%

Category 3 (3–4.5): ~35.1%

Category 4 (4.5–6): ~17.6%

Category 5 (6+): ~11.4%

EXERCISE 3

Random Split vs. Stratified Split (train_test_split)

Կիրառվող Կոդը

```
# Random Split
train_rand, test_rand = train_test_split(
    housing, test_size=0.2, random_state=42
)

# Stratified Split
train_strat, test_strat = train_test_split(
    housing, test_size=0.2, random_state=42,
    stratify=housing["income_cat"]
)
```

Արդյունք և Համեմատություն

Random Split: Առաջացնում է *sampling bias* (ընտրանքային կողմնակալություն), քանի որ որոշ եկամտային շերտեր կարող են սխալ արոպորցիայով անցնել test set:

Stratified Split: Երաշխավորում է ճշգրիտ համապատասխանություն ամբողջ բնակչության արոպորցիաներին:

EXERCISE 4

Test Set–ի անկախություն & Sampling Variability

Փորձարարական Կոդ

```
train1, test1 = train_test_split(  
    housing, test_size=0.2, random_state=42  
)  
print(test1['median_house_value'].mean())  
  
# Սերմի փոփոխություն  
train2, test2 = train_test_split(  
    housing, test_size=0.2, random_state=100  
)
```

Ինչու՞ է փոխվում միջինը

Sampling Variability: `random_state`-ը փոխելիս տողերը խառնվում են այլ կերպ, ինչից test set-ի միջին արժեքը փոքր-ինչ շեղվում է:

Ոսկե Կանոն: Test set-ը երբեք չի օգտագործվում մոդել ընտրելու համար (խուսափում ենք data leakage-ից):

Dataset-ի վտանգներ և լուծման ուղիներ

1. total_bedrooms (207 missing)

Problem: Մոդելները չեն ընդունում NaN արժեքներ:

Solution: Imputation (լրացնել մեդիանով) կամ տողերի հեռացում:

2. median_income (scaled / capped)

Problem: Արժեքները մասշտաբավորված են և կտրված ~15-ում:

Solution: Ստուգել metadata-ն, կիրառել clipping/capping:

3. median_house_value (capped at 500k)

Problem: Խեղաթյուրում է թանկ տների կանխատեսումները:

Solution: Հեռացնել այդ շենին հասած տները կամ հատուկ վերամշակել:

Dataset-ի վտանգներ և լուծման ուղիներ (Շարունակություն)

4. Right-skewed distributions

Problem: Աջ թեքվածությունը խանգարում է գծային մոդելներին:

Solution: Կիրառել լոգարիթմական փոխակերպում (որ. $\log(1+p)$):

5. ocean_proximity (categorical)

Problem: Մոդելները չեն հասկանում տեքստային արժեքներ:

Solution: Կիրառել One-Hot Encoding կամ Ordinal Encoding:

Պատրաստ է անցնելու առաջ!

Այժմ մենք վստահորեն կարող ենք անցնել "Explore and Visualize the Data"
բաժնին:

