

Machine Learning

Chapter 1: Հիմունքներ և Մոդելի Գնահատում

Train / Validation / Test բաժանումների և Model Selection-ի տրամաբանությունը

| Մեծ Պատկերը (The Big Picture)

Մեքենայի սովորում է տվյալներից, ոչ թե մենք ենք բոլոր կանոնները ձեռքով գրում:

- **Ավանդական մոտեցում:** Եթե (mail == "WIN") → spam
- **Machine Learning:** Տալիս ենք բազմաթիվ օրինակներ (Email → spam/ham), և մոդելն ինքն է հայտնաբերում օրինաչափությունները (patterns):

Հիմնական Շղթան

Data → Training Set → Learning Algorithm → Model →
Training → Validation / Tuning → Final Model → Test
→ Deployment → Monitoring

| Model-based vs Instance-based



Model-based

Training data-ից կառուցում է մաթեմատիկական մոդել՝ պարամետրերով:

Օրինակ՝ Linear Regression



Instance-based

Հիշում է օրինակները և նոր տվյալը համեմատում դրանց հետ (similarity):

Օրինակ՝ K-Nearest Neighbors

| Train Set & Test Set

Ինչո՞ւ է պետք Test Set-ը

Training data-ի վրա լավ աշխատելը բավարար չէ: Մենք պետք է իմանանք, թե ինչպես կաշխատի մոդելը **անծանոթ նոր տվյալների** վրա:

- **Training Set (օր. 80%):** Մոդելը սովորում է սրանից:
- **Test Set (օր. 20%):** Թաքցնում ենք մոդելից մինչև վերջնական ստուգումը:

80 / 20

Ստանդարտ բաժանման հարաբերակցություն

Մեծ dataset-ների դեպքում (օր. 10 մլն) նույնիսկ 99% / 1% բաժանումը կարող է լիովին բավարար լինել:

| Generalization & Overfitting



Generalization Error

Test set-ի վրա ստացված սխալը (կամ Out-of-Sample error) ցույց է տալիս իրական աշխատանքը:

Training error = 2%

Test error = 15%



Overfitting-ի Վտանգը

Եթե մոդելը չափից դուրս հարմարվել է training տվյալներին, նոր տվյալների վրա այն կծախողվի:

Դրա համար ուղղակի Production-ում փորձարկելը վտանգավոր է և կարող է հիասթափեցնել օգտատերերին:

| Model Selection & Hyperparameter Tuning

Ընտրության Բարդությունը

Ունենք տարբեր մոդելներ (Linear, Polynomial, Random Forest) և բազմաթիվ hyperparameters (λ regularization-ի համար):

- Փորձարկում ենք տասնյակ տարբերակներ
- Ընտրում ենք լավագույն պարամետրերը



Մեծ Թակարդը 🚓

Եթե մոդել ընտրելու համար անընդհատ օգտագործենք հենց Test Set-ը, այն այլևս «անծանոթ» չի լինի:

Test error-ը կլինի փոքր, բայց Real-world error-ը՝ շատ մեծ:

| Լուծումը` Validation Set

Dataset-ը բաժանում ենք երեք մասի` կանխելու համար test set-ի «փչացումը»:

- ● Training Set (60%): Մոդելը սովորեցնելու համար:
- ● Validation Set (20%): Մոդելների և hyperparameter-ների ընտրության համար:
- ● Test Set (20%): Վերջնական performance-ի մեկանգամյա ստուգման համար:

Բաժանման Սխեմա

Full Dataset

- └─ Training (60%)
- └─ Validation (20%)
- └─ Test (20%)

| Իրական Workflow-ի Քայլերը

Քայլ 1: Training set-ով train ենք անում
տարբեր մոդելներ (A, B, C)



Քայլ 2: Validation set-ով համեմատում ենք
(Ընտրում ենք լավագույնը)



Քայլ 3: Լավագույն մոդելը վերատրեյն ենք անում
(Training + Validation)



Քայլ 4: Միայն վերջում ստուգում ենք Test Set-ի
վրա

| Ամփոփ Աղյուսակ

Dataset-ի Տեսակը	Հիմնական Նպատակը	Հեշտ Հիշելու Համար
Training Set	Մոդելին սովորեցնել օրինաչափությունները	Train → Learn
Validation Set	Մոդելների և hyperparameter-ների ընտրություն	Validation → Choose
Test Set	Վերջնական performance-ի գնահատում	Test → Final Check

| Chapter 1 Complete Map

1. Data & Model Types

Supervised / Unsupervised, Batch / Online, Instance / Model-based learning, Bad data, Clean data.

2. Optimization

Overfitting, Underfitting, Regularization, Hyperparameter tuning, Validation strategy.

3. Production

Train/Val/Test workflow, Generalization error, Deployment, MLOps monitoring.

Հարցեր ունեք:

Անցնում ենք 10 գործնական խնդիրներին՝ այս ամենը կողի մեջ ամրապնդելու համար:

Machine Learning Fundamentals | Chapter 1 Review