

Machine Learning-ի Մարտահրավերները

Bad Data-ից մինչև Bad Algorithms, Irrelevant Features, Feature Engineering և Overfitting

1. Irrelevant Features & Garbage In → Out

Կանխատեսման Օրինակ

Տան գնի կանխատեսման ժամանակ ճիշտ features-ներն են՝

area, bedrooms, location, age

Բայց անիմաստ (irrelevant) features-ները միայն խանգարում են՝

owner_name, favorite_color, house_id

Հիմնական Կանոնը

Մոդելին ավելի շատ ինֆորմացիա տալը **միշտ չէ**, որ նշանակում է ավելի լավ մոդել:

Bad Data → Bad Features → Bad
Model → Poor Generalization

2. Feature Engineering



1. Feature Selection

Ընտրում ենք արդեն ունեցած features-ից ամենաօգտակարները:

100 features → 15 useful features



2. Feature Extraction

Մի քանի feature-ից ստեղծում ենք նոր, ավելի օգտակար feature (օրինակ՝ BMI):

height + weight → BMI



3. New Features

Հավաքում ենք նոր բացակայող տվյալներ՝ ճշգրտությունը բարելավելու համար:

distance_to_city_center

3. Overfitting-ը Machine Learning-ում

Մարդկային Overgeneralization

Գնում ես ուրիշ երկիր, մի տաքսիստ քեզ խաբում է: Դու միանգամից եզրակացնում ես. «Այս երկրի բոլոր տաքսիստները խաբեբաներ են»: Սա մեկ օրինակից չափազանց լայն եզրակացություն է:

ՄԼ-ում Overfitting-ի նշաններ

Մոդելը շատ լավ է սովորում training data-ն, բայց վատ է աշխատում նոր data-ի վրա:

Training accuracy: 99% (Անգիր է արել)

Test accuracy: 65% (Զի ճանաչում նորը)

4. Ինչո՞ւ է լինում Overfitting (Noise-ի օրինակ)

Բանաձևը

Small dataset + Complex model + Noisy data

↓ **OVERFITTING** ↓

Մոդելը բավականաչափ տվյալներ չունի և սկսում է սովորել պատահականությունները (noise):

«Երկրի անվան» զավեշտալի օրինակը

Life satisfaction կանխատեսելիս մոդելը նկատում է, որ New Zealand, Norway, Sweden անուններում կա "w" տառ:

Մոդելի «սխալ» եզրակացությունը.

Եթե երկրի անունում w կա → life satisfaction > 7

Rwanda-ի կամ Zimbabwe-ի դեպքում այս կանոնը կձախտղվի:

5. Ինչպե՞ս պայքարել Overfitting-ի դեմ



1. Simplify Model

Անցնել բարդ պոլինոմներից ավելի պարզ գծային մոդելների (Linear Model) կամ կրճատել features-ը:



2. More Training Data

1,000 նմուշից անցնել 100,000-ի:
Ավելի շատ տվյալները օգնում են տարբերել իրական pattern-ը noise-ից:



3. Reduce Noise

Ուղղել սխալ տվյալները, հեռացնել outliers-ները և մաքրել ամբողջ dataset-ը:

6. Regularization (Կանոնակարգում)

Ի՞նչ է Regularization-ը

Սա մոդելին սահմանափակելու արոցես է, որպեսզի այն չափազանց բարդ կամ ճկուն չդառնա:

Գծային մոդել՝ $y = \theta_0 + \theta_1 x$

Եթե ստիպենք $\theta_1 = 0$, ստանում ենք հորիզոնական պարզ գիծ: Իսկ եթե ստիպենք θ_1 -ին փոքր մնալ, մոդելը չափազանց ուժեղ չի թեքվի:



Model Complexity Control

Կանխում է չափազանց մեծ կորերի առաջացումը և բարելավում generalization-ը:

7. Հիմնական Հասկացությունների Ամփոփում

Հասկացություն	Նկարագրություն
Irrelevant Feature	Feature, որը որևէ օգտակար ինֆորմացիա չի տալիս մոդելին:
Feature Engineering	Selection (ընտրություն), Extraction (BMI) և New Features-ի ստեղծում:
Overfitting	Մոդելը չափից շատ է սովորում training data-ն ու noise-ը, վատ է generalize անում:
Regularization	Մոդելի բարդության և ճկունության սահմանափակում՝ overfitting-ը նվազեցնելու համար: