

Machine Learning Fundamentals

Bad Data-ից մինչև Bad Algorithms

Irrelevant Features, Feature Engineering և Overfitting-ի հիմնական սկզբունքները

1. Irrelevant Features

Անպետք և սխալ հատկանիշների ազդեցությունը մեքենայական ուսուցման
մոդելների վրա:

Garbage In → Garbage Out

✔️ Օգտակար Features (Տան գին)

Մոդելին օգնում են ճիշտ կանխատեսում անել.

- **area** (մակերես)
- **bedrooms** (սենյակաների քանակ)
- **location** (գտնվելու վայր)
- **age** (տան տարիք)

⚠️ Անպետք Features

Ավելի շատ տեղեկատվությունը միշտ չէ, որ նշանակում է ավելի լավ մոդել.

- **owner_name** (սեփականատիրոջ անուն)
- **favorite_color** (սիրելի գույն)
- **house_id** (տան նույնականացման համար)

2. Feature Engineering

Ամենակարևոր պրոցեսը, որը բաղկացած է երեք հիմնական մասից:

Feature Engineering-ի 3 Հիմնական Մասերը



1. Feature Selection

Ընտրում ենք արդեն ունեցած features-ից ամենաօգտակարները: Օրինակ՝ 100 հատկանիշից թողնում ենք միայն 15 օգտակարը:



2. Feature Extraction

Մի քանի feature-ից ստեղծում ենք նոր, ավելի օգտակար feature: Օրինակ՝ height + weight-ից ստանում ենք BMI:



3. Creating New Features

Հավաքում ենք նոր տվյալներ, երբ հասկանում ենք, որ գոյություն ունեցողները բավարար չեն (օրինակ՝ distance_to_city_center):

3. Overfitting 🔥

Մեքենայական ուսուցման ամենակարևոր և տարածված հասկացություններից մեկը:

Մարդկային և ML Overgeneralization

«Գնում ես ուրիշ երկիր: Մի տաքսիստ քեզ խաբում է: Ու դու ասում ես՝ բոլոր տաքսիստները խաբեբա են:»

— Մարդկային չափազանց լայն եզրակացություն (Overgeneralization)

Ինչ է կատարվում ML-ում?

Մոդելը շատ լավ սովորում է training data-ն, բայց վատ է աշխատում նոր տվյալների վրա:

- **Training Accuracy:** 99% (Անգիր է արել)
- **Test Accuracy:** 65% (Չի ճանաչում նոր դեպքերը)

Աղմկոտ (Noise) Օրինակ՝ Երկրի Անունը

Կանխատեսում ենք life satisfaction-ը և մոդելին տալիս ենք երկրների անունները: Մոդելը նկատում է պատահական օրինաչափություններ.

- New Zealand → 7.3
- Norway → 7.6
- Sweden → 7.3

Բոլորի անուններում կա "w" տառը: Մոդելը «սխալ» սովորում է, որ եթե w կա, ուրեմն life satisfaction > 7 է:

Արդյունքը

Եթե տանք նոր տվյալներ, ինչպիսին են **Rwanda**-ն կամ **Zimbabwe**-ն, այս «կանոնը» լրիվ կձախողվի:

Սա noise-ի pattern սովորելու վառ օրինակ է:

Ինչո՞ւ է Overfitting լինում և ինչպե՞ս պայքարել

Պատճառները

Model-ը չափազանց complex է տվյալների քանակի և noise-ի համեմատ:

Small Dataset + Complex Model + Noise = OVERFITTING

3 Հիմնական Լուծում

- **Simplify the model:** Նվազեցնել բարդությունը (օրինակ՝ High-degree Polynomial-ից անցնել Linear Model-ի):
- **Ավելի շատ training data:** 1,000-ից հասցնել 100,000+ մանրէ:
- **Reduce noise:** Մաքրել dataset-ը, հեռացնել outliers-ները և սխալները:

Regularization — Մոդելի Սահմանափակում

Regularization = մոդելին սահմանափակել, որպեսզի այն չափազանց բարդ չդառնա:

Եթե ունենք գծային մոդել՝ $y = \theta_0 + \theta_1 x$

- Եթե ստիպենք $\theta_1 = 0$, ստանում ենք հորիզոնական պարզ գիծ:
- Եթե ստիպենք $\theta_1 \rightarrow \text{small}$, մոդելը դեռ կարող է թեքվել, բայց շատ ուժեղ չի կարող ճկվել:

Նպատակը

Սահմանափակել մոդելի flexibility-ն (ճկունությունը), որպեսզի այն չսկսի սովորել տվյալների մեջ առկա պատահական աղմուկը (noise):

Model Complexity & Balance

Underfitting	Good Generalization (Balance)	Overfitting
Մոդելը չափազանց պարզ է	Ճիշտ հավասարակշռություն	Մոդելը չափազանց բարդ է
Training: Վատ Test: Վատ	Training: Լավ Test: Լավ	Training: Գերազանց Test: Վատ
Չի հասկանում օրինաչափությունը	Ընդհանրացնում է իրականությունը	Անգիր է արել noise-ը

Ինչ պետք է հաստատ իմանալ

- ✓ **Irrelevant Feature:** Feature, որը օգտակար information չի տալիս:
- ✓ **Feature Selection & Extraction:** Լավագույնների ընտրություն և նորերի ստեղծում:
- ✓ **Overfitting:** Մոդելը չափից շատ է հարմարվում training data-ին ու վատ generalize անում:
- ✓ **Regularization:** Մոդելի բարդության սահմանափակում՝ overfitting-ը նվազեցնելու համար:
- ✓ **Sampling Bias vs Overfitting:** Տվյալների հավաքման խնդիր vs մոդելի գերհարմարվածություն: