


MACHINE LEARNING PARADIGMS

Online Learning vs. Batch Learning

Մոդելների ուսուցման ռազմավարությունները, ճարտարապետական
տարբերությունները և կիրառության ոլորտները




1. Batch & Offline Learning

Ավանդական ուսուցման մոտեցումը, ռեսուրսների պահանջարկը և
Data Drift երևույթը

Batch Learning-ի էությունը

- **Ամբողջական Dataset:** Մոդելը սովորում է հասանելի ամբողջ տվյալներից միանգամից մեկ ընդհանուր փուլով:
- **Offline Ուսուցում:** Training-ից հետո մոդելը տեղադրվում է Production և այլևս ինքնուրույն չի սովորում:
- **Ռեսուրսատարություն:** Պահանջում է հսկայական CPU, RAM և ժամանակ ամեն վերապատրաստման համար:
- **Static Գիտելիք:** Production-ում միայն կիրառում է նախապես սովորած pattern-ները:



| Data Drift & Retraining

Data Drift (Model Rot)

Իրական աշխարհում տվյալների pattern-ները ժամանակի ընթացքում փոխվում են (օր.՝ spam email-ների նոր տեսակներ):

Քանի որ Offline մոդելը չի թարմանում, դրա ճշտությունը (performance) աստիճանաբար անկում է ապրում:



Retraining-ի Խնդիրը

Նոր տվյալներ ավելացնելու համար անհրաժեշտ է ամբողջ dataset-ը (հին + նոր) սկզբից կրկին train անել:

Մեծ տվյալների դեպքում սա պահանջում է հսկայական ֆինանսական, ժամանակային և հաշվողական ծախսեր:



2. Online Learning-ի Հիմունքները

Աստիճանական (Incremental) ուսուցում dynamic և արագ փոփոխվող
տվյալների համար



| Online Learning-ի մեխանիզմը



Աստիճանական Քայլեր

Մոդելը չի սպասում ամբողջ dataset-ի հավաքագրմանը: Այն սովորում է անմիջապես, երբ նոր տվյալ է ստացվում:



Single / Mini-Batches

Տվյալները մոդելին փոխանցվում են կամ մեկական instance-ով, կամ փոքր խմբերով (mini-batches):



Արագ & Էժան

Յուրաքանչյուր learning step կատարվում է շատ արագ և պահանջում է համեմատաբար քիչ հաշվողական ռեսուրս:

| Out-of-Core Learning

1 TB vs 16 GB

Dataset Size vs RAM Memory


Հսկայական Տվյալների Մշակում

Երբ dataset-ն այնքան մեծ է, որ չի տեղավորվում համակարգչի RAM-ում, Batch Learning-ն անհնարին է դառնում:

Լուծումը. Online/Incremental Learning-ի միջոցով տվյալները բեռնվում են փոքր մասերով (chunks), կատարվում է training, ապա ազատվում է memory-ն հաջորդ մասի համար:

Ե՞րբ օգտագործել Online Learning

- **Արագ փոփոխվող տվյալներ:** Ֆինանսական շուկաներ, stock market, live streaming feed-եր:
- **Սահմանափակ ռեսուրսներ:** Mobile devices, Edge computing, IoT սարքավորումներ:
- **Out-of-Core տվյալներ:** Հսկայական dataset-ներ, որոնք memory-ում չեն տեղավորվում:
- **Ակնթարթային adapt:** Մոդելն ակնթարթորեն հարմարվում է նոր pattern-ներին:



| Learning Rate & Forgetting



Բարձր Learning Rate

Մոդելն արագ է հարմարվում նոր ստացվող տվյալներին:

Ռիսկ՝ Catastrophic Forgetting. Մոդելը կարող է չափազանց արագ մոռանալ հին, բայց կարևոր pattern-ները (օր.՝ spam filter-ը մոռանա նախկին spam ձևերը):



Ցածր Learning Rate

Մոդելն ավելի դանդաղ է սովորում, բայց ապահովում է բարձր կայունություն:

Առավելություն. Ավելի քիչ է ազդվում պատահական աղմուկից (noise) և նոր տվյալների անոմալիաներից:

| Online Learning-ի Ռիսկերը

Վատ տվյալների (Bad Data) Վտանգը

Եթե համակարգին սխալ կամ աղտոտված տվյալներ փոխանցվեն (օր.՝ փչացած sensor կամ մանիպուլյացիա), Online մոդելն արագ կսկսի վատ սովորել և performance-ը կտրուկ կընկնի:

Production Monitoring-ի Անհրաժեշտություն

Անհրաժեշտ է անընդհատ վերահսկել մոդելի աշխատանքը: Performance-ի անկման դեպքում learning-ը պետք է ժամանակավորապես անջատել և վերադառնալ նախորդ կայուն մոդելին:



System Alert: Data Noise

Performance Degradation Detected

Fallback to Backup Model

Batch vs Online Համեմատություն

Հատկանիշ	Batch Learning	Online Learning
Տվյալների մոտեցում	Ամբողջ dataset-ը միանգամից	Հերթով / փոքր մասերով (mini-batches)
Ուսուցման ոճը	Սկզբից ամբողջական dataset-ով	Incremental (աստիճանական)
Նոր տվյալներ	Ամբողջական retraining (from scratch)	Արագ model update
Memory պահանջ	Շատ բարձր (ամբողջ data-ն RAM-ում)	Համեմատաբար ցածր
Մեծ Dataset-ներ	Դժվար / Սահմանափակ	Out-of-Core learning-ով հնարավոր
Հիմնական Ռիսկ	Data Drift / Model Rot	Bad Data-ից performance-ի անկում

Հարցեր և Քննարկում

Շնորհակալություն ուշադրության համար!

Machine Learning Paradigms | Batch & Online Learning Guide