

MACHINE LEARNING HANDS-ON GUIDE

Stratified Sampling & Test Set Creation

Ինչպես ճիշտ բաժանել տվյալները և պահպանել ներկայացուցչական բաշխումը

Random vs. Stratified Split

Pure Random

Կարող է խախտել կարևոր հատկանիշների բաշխումը train և test բաժանումներում:

Stratified Sampling

Ապահովում է, որ հիմնական կատեգորիաների հարաբերակցությունը խստորեն պահպանվի:

Pipeline-ի Հիմնական Քայլերը

1. Median Income

Շատ կարևոր անդադար
փոփոխական:

2. `pd.cut()`

Ստեղծում ենք
կատեգորիաներ
(`income_cat`):

3. Split

Իրականացնում ենք
stratified բաժանում:

4. Cleanup

Հեռացնում ենք
ժամանակավոր `income_cat`-
ը:

Ինչպես է աշխատում `split()`-ը

`splitter.split()`

Վերադարձնում է `index`-ների հավաքածու (`train_index`, `test_index`)

`housing_full.iloc[]`

Ստանում ենք իրական `DataFrame`-ները

Ինչու՞ $n_splits = 10$

Մի քանի Split-ներ

Ստեղծում է 10 տարբեր stratified train/test տարբերակներ նույն dataset-ից:

Cross-Validation

Նախապատրաստություն է հաջորդ գաղափարներին՝ մոդելի միջին performance-ը գնահատելու համար:

Ավելի Կարճ Ճանապարհ

train_test_split() ֆունկցիան

Կարիք չկա ձեռքով գրել ամբողջ StratifiedShuffleSplit-ը, եթե պետք է միայն մեկ split:

stratify = housing_full["income_cat"] parameter-ը անում է ամբողջ աշխատանքը:

Արդյունքների Ստուգումը

Category 3
~35%

Category 2
~32%

Category 4
~18%

Category 5 & 1
11% & 4%

Ինչու՞ ենք ջնջում `income_cat`-ը

Ժամանակավոր սյունակ

Այն ստեղծվել էր բացառապես stratified sampling անելու և բաշխումը վերահսկելու համար:

Մաքրում `split`-ից հետո

train-ից և test-ից հեռացնում ենք այն: Իսկ բնօրինակ `median_income`-ը մնում է անփոփոխ:

Test Set-ի ստեղծումն ավարտված է

Հաջորդ փուլ՝ Explore and Visualize the Data to Gain Insights
(տվյալների վերլուծություն և նոր օրինաչափությունների
բացահայտում):