

MACHINE LEARNING FUNDAMENTALS

Stratified Sampling

Ինչպես լուծել Sampling Bias-ի խնդիրը և ապահովել տվյալների ճիշտ
բաշխումը



1. Phone Book–ի օրինակը

Պատահական ընտրության վտանգը ամբողջ բնակչության տվյալներում

RANDOM SAMPLE (ՍԽԱԼ)

600 Female / 400 Male

Պատահական ընտրությունը կարող է խեղաթյուրել իրական համամասնությունը:

REAL POPULATION (ՃԻՇՏ)

51.6% Female / 48.4% Male

Sample-ը պարտադիր պետք է արտացոլի բնակչության իրական կառուցվածքը:

2. Stratified Sampling–ի էությունը

Բնակչության բաժանում համասեռ խմբերի՝ strata-ների

1. Strata–ների ստեղծում

Population–ը բաժանում ենք հստակ խմբերի (օրին՝ Female և Male):

2. Համամասնության պահպանում

Յուրաքանչյուր խմբից վերցնում ենք ճշգրիտ քանակ (Female: 516, Male: 484):

3. Վստահելի արդյունք

Sample–ը լիովին ներկայացնում է ամբողջ population–ը:

3. Հիմա մեր Housing Dataset-ը

Ինչու՞ է median_income-ը կարևոր և ինչպես բաժանել այն interval-ների

Կարևոր Feature

Housing price-ը կանխատեսելու համար median_income-ը հիմնական գործոնն է: Test set-ը պարտադիր պետք է ներկայացնի այս բաշխումը:

Continuous vs Categorical

Քանի որ արժեքները անվերջ continuous թվեր են, հնարավոր չէ առանձին strata սարքել. դրանք խմբավորվում են interval-ների մեջ:

4. `pd.cut()` ֆունկցիան

Continuous թվերի վերածումը 5 կատեգորիաների (Income Categories)

```
housing_full["income_cat"] = pd.cut(  
    housing_full["median_income"],  
    bins=[0., 1.5, 3.0, 4.5, 6., np.inf],  
    labels=[1, 2, 3, 4, 5]  
)
```

Cat1: 0 - 1.5

Cat2: 1.5 - 3

Cat3: 3 - 4.5

Cat4: 4.5 - 6

Cat5: 6 - ∞

5. Ինչու՞ է սա անհրաժեշտ

Համամասնությունների վերահսկում train և test սեթերում

Dataset-ի բաշխումը

Յուրաքանչյուր կատեգորիա ունի հստակ տոկոսային հարաբերակցություն ամբողջ տվյալների բազայում (օրին՝ Cat 3-ը՝ 30%):

Test Set-ի նպատակը

Մենք պահանջում ենք, որ test set-ում նույնպես պահպանվեն այս նույն տոկոսները՝ ապահովելով մոդելի ճշգրիտ գնահատականը:

6. Զգուշացում. Մի՛ ստեղծեք շատ strata

Շատ կատեգորիաները կարող են փչացնել վիճակագրական վստահությունը

Վտանգը (100 կատեգորիա)

Եթե ստեղծես շատ կատեգորիաներ, որոշներում կարող է մնալ ընդամենը 1–2 district, ինչը վիճակագրորեն անվստահելի է:

Ոսկե կանոն

Strata-ները չպետք է շատ լինեն, և յուրաքանչյուր stratum պետք է բավարար չափով մեծ լինի:

7. Վերլուծություն և Վիզուալիզացիա

Տվյալների բաշխման ստուգում Python-ում

```
cat_counts = housing_full["income_cat"].value_counts().sort_index()  
cat_counts.plot.bar(rot=0, grid=True)
```

Category 1
822

Category 2
6,581

Category 3
7,236

Category 4
3,634

Category 5
2,367

Ամփոփում

Random Sampling-ն առաջարկում է «պատահական վերցնել 20%-ը»,
մինչդեռ Stratified Sampling-ը պահպանում է կարևոր խմբերի
համամասնությունը:

Հաջորդքայլը՝ `StratifiedShuffleSplit` Scikit-Learn-ում 🚀