

Machine Learning / Data Analysis

Հաճախորդների Տվյալների Նախամշակում և Վերլուծություն

Python, Pandas, Matplotlib և Scikit-Learn փաթեթներով տվյալների վերլուծության և Standard Scaling-ի ամբողջական ակնարկ

Մաս 1. Տվյալների Ստեղծում և EDA

Սինթետիկ տվյալների բազայի ձևավորում և սկզբնական հետազոտական վերլուծություն

1.1 Սինթետիկ Տվյալների Գեներացում

Հատկանիշների Ընտրություն

Կողմ օգտագործում է `np.random` գրադարանը՝ 1000 հաճախորդների համար 4 առանցքային ցուցանիշներ ստեղծելու համար.

- **Age:** 18 - 70 տարեկան
- **Annual Income:** \$20,000 - \$120,000
- **Spending Score:** 1 - 100 միավոր
- **Visits per month:** 1 - 20 այցելություն

DataFrame Կառուցվածք

Տվյալները միավորվում են **Pandas DataFrame**-ում՝ հետագա մշակման համար:

`make_blobs` ֆունկցիան սկզբում օգտագործվում է 4 կլաստերային կենտրոններով սինթետիկ կետեր գեներացնելու համար:


1.2 Տվյալների Որակի Ստուգում

Անվտանգություն և Ամբողջականություն

Մինչ մոդելավորումը, կոդն իրականացնում է EDA-ի (Exploratory Data Analysis) կարևորագույն ստուգումները՝ `df.isnull().sum()` և `df.duplicated().sum()`:

Արդյունքում հաստատվում է, որ տվյալների բազան չունի **բացակայող արժեքներ (Missing Values)** կամ **կրկնվող տողեր (Duplicates)**, ինչը երաշխավորում է վերլուծության ճշգրտությունը:

Machine Learning Pro



1.3 Վիզուալ Վերլուծություն (Visual EDA)



Histograms

Գծագրվում են բոլոր 4 հատկանիշների բաշխվածության հիստոգրամները (bins=20)՝ տվյալների տարածվածությունը տեսնելու համար:



Scatter Plots

Վերլուծվում են Income, Age, Visits ցուցանիշների կապը Spending Score-ի հետ՝ կլաստերային խմբավորումներ նկատելու համար:



Correlation Matrix

`df.corr()` և
`plt.imshow(cmap='coolwarm')`
միջոցով կառուցվում է հատկանիշների փոխկապակցվածության քարտեզը:

1.4 Տվյալների Հիմնական Ցուցանիշները

1,000

Վերլուծված Հաճախորդներ

Տվյալների Ծավալը և Ամփոփումը

Dataset-ը պարունակում է 1000 տող և 4 սյունակ (Shape: 1000x4):

`df.describe()` ֆունկցիան հաշվարկում է յուրաքանչյուր հատկանիշի միջին արժեքը (mean), ստանդարտ շեղումը (std), նվազագույն և առավելագույն արժեքները:

Մաս 2. Feature Scaling (Ստանդարտացում)

StandardScaler-ի կիրառումը K-Means կլաստերավորման մոդելի նախապատրաստման համար

2.1 StandardScaler-ի Մաթեմատիկական Մոդելը

Standard Scaling Բանաձևը

Scikit-Learn-ի **StandardScaler**-ը ձևափոխում է տվյալները այնպես, որ դրանց միջինը դառնա 0, իսկ ստանդարտ շեղումը՝ 1:

$$z = \frac{x - \mu}{\sigma}$$

Որտեղ x -ը սկզբնական արժեքն է, μ -ն միջինն է (mean), իսկ σ -ն ստանդարտ շեղումը (std):



2.2 Վիճակագրությունը **Scaling**-ից Առաջ և Հետո

Հատկանիշ (Feature)	Միջինը (Մինչև)	Std (Մինչև)	Միջինը (Scaling-ից հետո)	Std (Scaling-ից հետո)
Age	~44.0 տարեկան	~15.0	0.00	1.00
Annual Income	~\$70,000	~\$28,000	0.00	1.00
Spending Score	~50.5 միավոր	~28.5	0.00	1.00
Visits per month	~10.5 այցելություն	~5.7	0.00	1.00

2.3 Ինչու՞ է Ստանդարտացումը Կարևոր **ML**-ում



Մաշտաբների հավասարեցում: Annual Income-ը (\$20k-\$120k) ունի շատ ավելի մեծ թվային տիրույթ, քան Visits-ը (1-20): Առանց scaling-ի, Income-ը կգերիշխեր հեռավորության հաշվարկման ժամանակ:




Distance-based Ալգորիթմներ: K-Means-ը, KNN-ը և PCA-ն օգտագործում են էվկլիդյան հեռավորություն (Euclidean Distance), ուստի բոլոր հատկանիշները պետք է ունենան նույն կշիռը:



Boxplot Վիզուալիզացիա: Կոդի վերջին հատվածը գծագրում է `plt.boxplot()` մինչև scaling-ը և scaling-ից հետո՝ ցույց տալով բոլոր հատկանիշների բերումը միասնական [-3, 3] տիրույթ:

2.4 Փայիլայնի Ամբողջական Փուլերը (Pipeline)




Հարցեր և Քննարկում

Շնորհակալություն ուշադրության համար:

</> Customer Segmentation Data Pipeline Complete

Image Sources



https://media.geeksforgeeks.org/wp-content/uploads/20251124151113659326/the_machine_learning_process.webp

Source: www.geeksforgeeks.org



https://static.vecteezy.com/system/resources/thumbnails/079/504/560/small_2x/abstract-3d-big-data-visualization-with-glowing-blue-network-mesh-and-orange-data-bar-chart-ri-sing-from-digital-grid-futuristic-analytics-business-intelligence-and-data-science-technology-video.jpg

Source: www.vecteezy.com